

华中科技大学

本科生毕业设计

基于情感的深度学习对话生成 关键技术研究

院 系 计算机科学与技术

专业班级 CS1703

姓 名 范唯

学 号 U201714670

指导教师 魏巍

2021 年 6 月 1 日

学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包括任何其他个人或集体已经发表或撰写的成果作品。本人完全意识到本声明的法律后果由本人承担。

作者签名： 年 月 日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保障、使用学位论文的规定，同意学校保留并向有关学位论文管理部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权省级优秀学士论文评选机构将本学位论文的全部或部分内容编入有关数据进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

本学位论文属于 1、保密 ☐，在 年解密后适用本授权书。

2、不保密 ☐。

(请在以上相应方框内打“√”)

作者签名： 年 月 日

导师签名： 年 月 日

摘 要

现如今，人工智能以及大数据从方方面面不断地影响着人们的生活。而许多智能 AI 助手已经可以非常准确的理解用户意图并给出贴切的回复。然而这距离图灵的终极构想还相去甚远，机器能否表达出和人相匹配的智能依旧是目前的一大难题。因为人类在交流过程中，除了理性的信息传输外，还有情感的交互夹杂其中，这类信息是隐式却至关重要的，所以想要进一步提升人机对话的沉浸感，则必须要在对话生成中加入情感因素的考量。

新的情感对话系统在原先的基础上加入了情感自动选择模块，而不需要再进行人为的介入。整个系统从算法设计上来说，在序列到序列模型的基础上加入了注意力机制、情感嵌入和语义嵌入。而从模块上来看，主要包括情感选择模块和回复生成模块。它不仅能准确回复用户的问题，还能在回复中融入适当的情感。新系统的展示界面前端则采用 Vue.js 来设计，同时，后端服务则使用 Django 框架，这不仅能直观的展现对话系统功能，更提高了交互的体验感。

新的系统不仅使回复具有多样性并与主题相关，避免统一而通用的回复，还使得生成的回复富有情感完全不依赖于手动标注。完美地解决了当下人机对话系统中自动生成回复十分生硬的缺点，而用户体验也随之增强。

关键词：情感对话生成；情感对话机器人；注意力机制；序列到序列模型；情感嵌入

Abstract

Nowadays, artificial intelligence and big data continue to affect people's lives in all aspects. Artificial intelligence assistants can already understand users' intentions accurately and give appropriate responses. Nevertheless, this is still far from Turing's ultimate conception. Whether the machine can express the intelligence that matches the human is a big problem at present. Because in the process of human communication, besides logical information transmission, there are emotional interactions. This type of information is implicit but crucial. Therefore, if we want to further enhance the immersion of human-machine dialogue, we must consider emotion factor in dialogue generation.

The new emotional dialogue system adds an automatic emotional selection module on the original basis, without the need for human intervention. In terms of algorithm design, the entire system is based on sequence to sequence model with attention mechanism, emotional embedding and semantic embedding. From the perspective of modules, it mainly includes an emotion selection module and a response generation module. Not only can it accurately respond to the users' post, but also in the responses incorporate appropriate emotions. The front-end of the new system is designed using Vue.js, while the back-end server uses the Django framework, which not only visually displays the functions of the dialogue system, but also improves interactive experience.

The new system makes the responses more diverse and relevant to the topic, avoiding uniform and universal replies, and also makes the generated responses full of emotion and does not rely on manual annotation at all. It perfectly solves the shortcoming of the current dialogue system that automatically generated responses are very blunt, and meanwhile, the user experience is also enhanced.

Key Words: emotional dialogue generation, emotional chatbot, Attention Mechanisms, Sequence to Sequence, sentiment embedding

目 录

摘要	I
Abstract	II
1 绪论	1
1.1 课题背景	1
1.2 国内外研究现状	1
1.3 研究目的和主要内容	2
1.4 论文结构	3
2 技术背景概述	5
2.1 词嵌入	5
2.2 循环神经网络	7
2.3 序列到序列模型	9
2.4 注意力机制	11
2.5 本章小结	12
3 基于注意力机制 (Attention) 的情感对话生成系统设计	13
3.1 基于融合预测网络的情感选择模块	14
3.2 基于内部外部记忆的回复生成模块	20
3.3 损失函数	24
3.4 设计中考虑的制约因素	24
3.5 成本估算	26
3.6 本章小结	27
4 基于注意力机制 (Attention) 的情感对话生成系统实现	28
4.1 系统主体架构实现	28
4.2 基于融合预测网络的情感选择器	32
4.3 基于内部外部记忆的回复生成器	33
4.4 本章小结	35
5 性能评估与分析	36
5.1 测试环境与方案	36

5.2	自动评估	37
5.3	人工评估	38
5.4	系统界面	39
5.5	本章小结	40
6	总结与展望	41
6.1	个人总结	41
6.2	未来展望	41
	致谢	43
	参考文献	44

1 绪论

在本章节中，首先会概述课题背景，然后展开描述国内外对于情感对话生成的研究现状，并且论述本课题的主要研究内容和方向。

1.1 课题背景

在自动对话系统日益完善的今天，人机对话已经在我们的生活中非常普及了，比如 Siri、小度、小爱同学、天猫精灵等等，但是业界中普及的一般是传统的问答模式，用户能很明显的感受到这是来自机器人的回复，简单直接且富有理性。但是，研究发现在对话中加入情感因素，会大幅度提高整个对话的流畅程度和用户满意度。

目前现存的情感对话生成系统，大多是基于朱小燕、黄民烈老师团队开发的 Emotion Chat Machine^[1] 的一些变体，虽然能生成富有情感的回复，但是存在的问题是非常依赖于手动选择情感，在用户使用体验上较差。所以该类系统需要改进的地方是（1）生成的回复富有情感且完全不依赖于手动标注；（2）回复具有多样性并与主题相关；（3）避免统一而通用的回复。基于此，对传统 ECM 模型进行优化改进有着重要的意义。

1.2 国内外研究现状

现有的对话生成模型主要是基于序列到序列架构 (Seq2seq)，这种架构可以有效的解决序列映射问题，且被广泛用于各大领域，其中主要包括机器翻译和图像标题。

首先在原生 Seq2seq 架构的研究工作中，Bahdanau^[2] 等人使用双向长短期记忆网络 (Bi-LSTM) 的神经注意力机制去捕获句子中的重要语义信息，并且该架构能自动搜索上下文中的相关部分。Luong^[3] 等人则非常详尽地评估了具有不同注意力机制的序列到序列架构的性能。Jean^[4] 等人提出了使用采样分类器的方法来解决巨量词汇引发的解码复杂度过高的问题。这些工作显著地提升了 Seq2seq 模型的生成性能，并且加快了编/解码过程，为此后基于此架构的研究工作奠定

了十分坚实的基础。

在近几年的研究中，科研人员还致力于研究如何将 Seq2seq 模型应用于对话系统，并且提出了不同的变体来解决不同特定领域的特定问题，例如主题感知模型、最大信息交互模型、层级循环模型、增强型定向搜索模型等等，来产生更多元且更有信息含量的回复。并且随着研究的深入，逐渐将对话模型分为闲聊机器人与特定领域服务机器人。

在回复内容多样性方面，彭^[5]等人提出了基于变分自编码的情感对话模型 (VAE-ECG)，该架构利用来 VAE 的特性来更好更准确的对文本的潜在语义进行建模，使得生成的回复内容具有更好的拓展性。刘^[6]等人则基于对话风格迁移的对话神经网络，提出了融合检索结果机制的生成对话模型，来避免重复单一的通用性回复。而诸多研究表面情感因素对于成功建立起拟人对话生成模型具有重要意义，Ghosh^[7]等人于 2017 年提出了情感语言模型，该模型可以根据指定的情感类别和情感强度来生成对应的结构化语言。Zhou 等人^[1]所提出的基于条件和强化学习的自动编码框架，同样也是在给定的情感下生成最为合适的回复，刘^[8]等人提出了基于 PAD 情感状态模型的对话生成框架，PAD 简单直接的将情感纬度分为愉悦度、激活度和优势度，理论上可以使用这三个维度来表示所有的情感。但是上述的研究一直致力于提升生成回复的流利度和情感丰富度，但都需要人来手动介入去选择注入最佳的情感类别，显然这是十分不理想的。所以本课题的主要研究方向则是在 Zhou^[1]等人的传统 ECM 框架下进行升级，加入自动情感选择模块。

1.3 研究目的和主要内容

目前来说，对话模型主要是使用序列到序列模型 (Sequence to Sequence)，序列到序列 (Seq2seq) 注意力模型通常是基于深度 RNN 的编码/解码器的体系结构。但是该模型在情感对话上存在着以下几个关键性问题：

(1) 回答缺乏多样性，即容易产生通用回答，这是因为语料库中存在大量多对一的回答使得模型回答比较单一。

(2) 缺少情感的编码和解码，即模型不考虑回答和问题之间的情感关系，只关心逻辑关系。

(3) 需要手动选择最佳的情感类别，没有情感自动选择模块。

基于以上三个主要问题，本课题中的模型构建将主要聚焦于以下三点：

(1) 语义嵌入 (Semantic Embedding)，基于注意力机制针对文本中的主题相关词进行建模，并在回复中围绕主题相关词语进行相似性扩展。

(2) 情感嵌入 (Sentiment Embedding)，将情感理解成一种特殊的语义来进行编码，将其作为语义和主题的一个维度来进行嵌入，使生成的回复具有与主题联系更密切的情感倾向。

(3) 最佳情感选择器^[9] (Optimal Emotion Selector)，因为实际对话过程中不会有人实时来为回复进行情感选择，所以自动情感选择模块显得尤为重要。但值得注意的是情感选择并不只是单纯的将 post 中的情感提取出来，然后在 response 中复用。因为不会有人想在生气的阐述观点时，听到对方也愤怒的回复他。

而且在之前的情感对话生成中，回复中所嵌入的情感都是单一的情感，但是人类对于情感的感知十分微妙，在言语中所包含的情感也不是只有一个种类，所以在本课题中提出了情感向量空间^[10] 并且假定情感概率的分布在整个向量空间上，从而使得生成的回复不会被单一的情绪所约束。此外，同样也希望能为聊天机器人注入自我角色和情感偏好，也就是独有的性格，能让它在对话生成过程中有自己独立的个人身份和语言风格^[11] (比如积极、悲观、易怒、可爱甜美等)，而不是完全取决于用户的情感输入来产生对应的情绪，但这并不是此次课题的主要研究内容，可作为未来展望。

1.4 论文结构

本文的主要结构如下：

第一章中简明扼要地介绍了本课题的背景，情感对话生成模型的国内外研究现状，以及原有的模型架构存在的诸多问题，并提出了大致的优化改进方案。

第二章详细阐明了系统相关的技术背景，其中包含了词嵌入原理、序列到序列模型、注意力机制等算法模型的底层逻辑。

第三章介绍系统的整体结果设计，主要由情感选择模块与回复生成模块两大部分构成，并描述了展示界面的前后端设计逻辑。

第四章基于前面的设计部分进行具体实现，主要包括系统主体架构实现，以

及基于 TensorFlow 开发的的情感选择器和回复生成器。

第五章中描述了测试环境与基本方案，并横向对比了相似模型架构的测试结果，其中评估的主要内容包括语义流畅度与情感准确度，以及 Vue.js+Django 的交互展示界面的实现。

第六章是对整个研究工作的总结与展望，总结了本系统相较于前人研究工作的优势，并展望未来能迭代升级的模块。

2 技术背景概述

2.1 词嵌入

在进入神经网络训练之前，需要先进行预训练，其中主要包括词嵌入 (Word Embedding)，词嵌入的作用是把一个维度数量为所有词总数的高维空间，嵌入到一个维数低很多的连续的向量空间中，且每个单词或词组被映射为实数域向量。因为神经网络是无法识别直接的语言文字的，所以只能将其转换为张量来进行训练。

而最简单的映射编码方式是 one-hot encoding，譬如如果一个字典和字库里一共有 N 个单词，比如 boy, girl, man, woman 这四个单词，它们的 one-hot 编码应该是：

$$boy = [1, 0, 0, 0]$$

$$girl = [0, 1, 0, 0]$$

$$man = [0, 0, 1, 0]$$

$$woman = [0, 0, 0, 1]$$

但是显然这种编码方式无法判断出相似词语的关系，因为在这个向量空间中，任何两个词语的距离都是一样的，而理想的情况应该是 $distance(boy, man) = distance(girl, woman)$ ，所以需要用到其他词嵌入算法，其中最为经典的应该是 Word2Vec，以下为本课题中所用的词嵌入技术详解。

Word2Vec 是一种可以从大量文本语料中使用无监督的方式学习而它的范畴中目前主要包括两种类型：Skip-Gram^[12] 和 CBOW，从本质区别上来说，Skip-gram 是给定中间输入的 word 来预测上下文。相反的是，CBOW 是给定上下文，来预测中间的 word。如图2-1所示

而本课题中用到的词嵌入算法就是 Skip-gram，Skip-gram 模型是输入一个单词，例如 x_t 输出是 $\{x_{t-1}, x_{t-2}, x_{t+1}, x_{t+2}\}$ ，上下文窗口大小为 4。举例来说的话，这里有个句子 “I want to drive my car to school”。如果将 “car” 作为训练输入数




图 2-1 CBOW vs Skip-gram 对比原理图

据，单词组“I”，“want”，“to”，“drive”，“my”，“to”，“school”就是输出。

而如何得到词向量，是本小节论述的重点内容，以“I want to drive my car to school.”为例。

首先输入的是一个 one-hot 向量，假设整个语料库中有 10000 个词，那输入一个 1×10000 的 one-hot 矩阵来表示 car，接下来隐藏层设置为 300 个神经单元，这个 300 个神经单元就是所需要的维度，如果想要设置成 100 维的词向量，那么就把神经元个数就设置成 100。这个取决于实际预训练的需求。

然后在输入和隐藏层之间，就会产生一个大小为 10000×300 的权重矩阵，而这个矩阵就是所需要的词向量。如何计算这么庞大的词向量，那么需要看接下去的连接。

这时候会得到 10000 个输出，再将这 10000 个输出代入 softmax 并转化为 10000 个概率，显然这 10000 个概率值相加总和为 1。

这是一个完整的 skip-gram 的网络层。以 car 为例，将形成四组训练数据 (car, drive)、(car, my)、(car, to)、(car, school)。

下面进行权重优化，拿 (car, drive) 来说，car 的输出为 10000 个概率分布，形式为 1×10000 ，而 drive 为一个 1×10000 的 one-hot 形式，loss function 代价函数可以最小化两个矩阵的交叉熵，也可以求出两个矩阵的差平方，即损失值。

再经过不断的迭代后，输入层和隐藏层在最终会形成一个大小 10000×300 的权重矩阵，而求得的权重矩阵一一对应到输入层当中词汇向量。大小同样也为 10000×300 。详细过程如图2-2所示。

而业界也有许多开源的预训练词向量项目，例如^[13]，也是本课题中所使用到词向量集，因为本课题主要是设计一款闲聊机器人，所以使用到的为微博用户的发言数据，维度大小为 300。

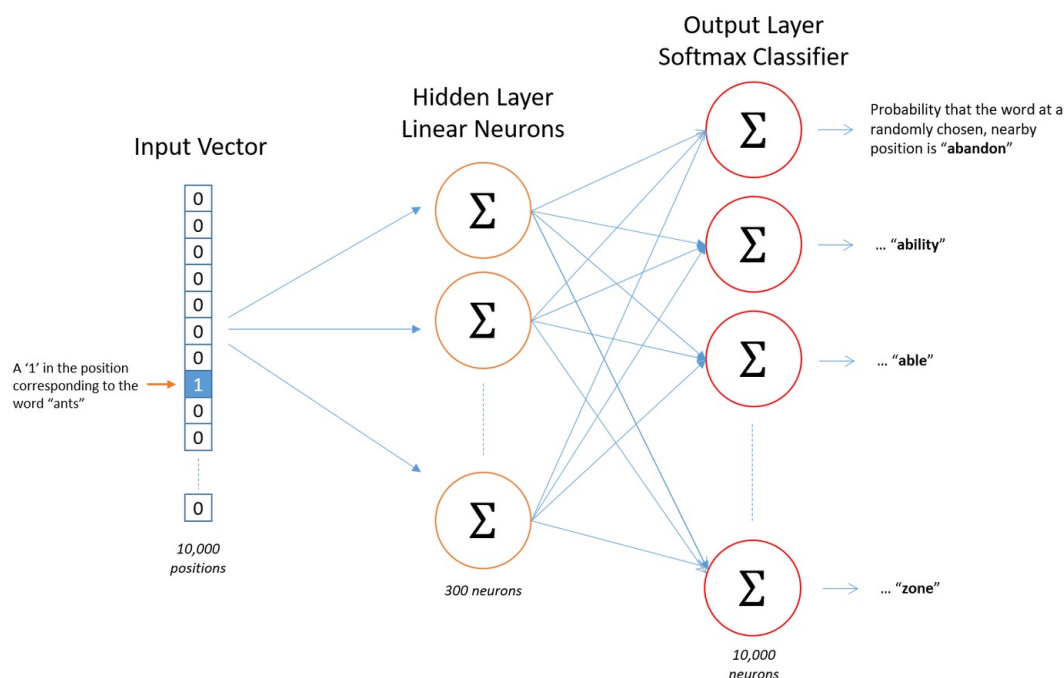


图 2-2 Skip-gram 原理图

2.2 循环神经网络

循环神经网络，简称 RNN^[14]，其基本思想是利用序列信息进行学习。因为在传统的神经网络中输入和输出都是相互独立的，然而如果想预测一个句子下一个单词，则需要知道之前的 word 都有哪些。

如图2-3为 RNN 单元展开图，之所以被称为循环，是因为它们对于句子中的每个元素会执行同样的任务，且输出会依赖于上一步的计算。从另外一个层面来理解的话，RNN 可以使用记忆来获得之前所有计算过的信息。通过展开 RNN，可以获得完整序列网络，如果句中单词数为 10 个，那么就展开成 10 层神经网络，每个单词一层。而 RNN 单元中的计算过程如下。

- x_t : 时刻 t 的输入, 例如 x_t 为 one-hot 编码的句子中的第二个单词
- h_t : 时刻 t 的隐藏状态, 是网络的 memory 结构, h_t 的计算表达式为 $h_t = f(Ux_t + Wh_{t-1})$
- o_t : 时刻 t 的输出, 如果需要预测一个句中的下个单词, 那么输出则为字典中所有单词的概率所组成的向量, 表达式为 $o_t = \text{softmax}(Vh_t)$




图 2-3 RNN 展开原理图

此外需要注意的是:

- 可以将隐藏状态 h_t 视为网络的存储器, 获得先前时间中发生的信息, 并且仅使用时间 t 处的存储器来计算输出。如前所述, 这种情况稍微复杂一些, 因为实际上只能获得一定时期的信息。
- 传统的神经网络在每个层中使用不同的参数, 而 RNN 在所有步骤中都使用公共参数 (U, V, W), 这意味着我们在每个步骤中执行相同的任务, 但只有输入是不同的。这将减少需要学习的参数数量
- 图2-3是每个步骤都在输出, 这不是绝对必要的, 需要针对不同的任务进行设计。例如, 当预测一个句子的情感时, 只关心最终的输出, 而不关心每个单词之后的情感值。同样也不必每次都输入信息。RNN 的主要特征是隐藏状态, 它可以间接的用于获取句子的信息。

而 RNN 也有许多不同的种类来应对不同的需求。

- one-to-one: 就是最普通的神经网络, 几乎不能算是 RNN, 这种情况可以省略 $a_{<0>}$ 。
- one-to-many: 常用于 music generation、image captioning。
- many-to-one: 常用于 sentiment classification

- many-to-many (输入输出等长): 常用于 video classification on frame level。
- many-to-many (输入输出不等长): 常用于 machine translation，前一部分的作用是 encoder，后一部分作用是 decoder。

2.3 序列到序列模型

序列到序列 (Sequence to Sequence) 模型由两部分组成: Encoder 和 Decoder, 每一个部分都是由一个 RNN Cell 结构, 在本课题中选择了 GRU 来作为 RNN Cell 子结构。传统的序列到序列模型, 是通过 Encoder 把一个序列编码称为固定长度语义向量, 然后 Decoder 再将其解码为输出序列。而该模型, 便是上一小节中提到的 many-to-many 可变长度结构的 RNN 模型, 输入和输出序列的长度可以不相同。这类框架由 Cho^[15] 等人提出, 同时也提出了 GRU。如图2-4所示, 在




图 2-4 序列到序列模型原理图

Encoder 中, 主要关注的是隐藏状态 h_t 的生成, 如下公式:

$$h_t = \tanh(W[h_{t-1}, x_t] + b) \quad (2.1)$$

最终 Encoder 输出语义向量为:

$$c = \tanh(Uh_T) \quad (2.2)$$

在 Decoder 中

$$h_t = \tanh(W[h_{t-1}, y_{t-1}, c] + b) \quad (2.3)$$

$$o_t = \text{softmax}(Vh_t + c) \quad (2.4)$$

而 Decoder 接收到 Encoder 传入的语义向量 c 之后, 首先会输入 $\langle START \rangle$ 信号, 和初始化 h_0 隐藏向量, 然后按照公式2.3和2.4来进行循环计算。

$$h_1 = \tanh(W[h_0, y_0, c] + b)$$

$$o_1 = \text{softmax}(Vh_1 + c)$$

$$h_2 = \tanh(W[h_1, y_1, c] + b)$$

$$o_2 = \text{softmax}(Vh_2 + c)$$

...

$$h_t = \tanh(W[h_{t-1}, y_{t-1}, c] + b)$$

$$o_t = \text{softmax}(Vh_t + c)$$

其中 o_t 是一个向量, 是每个时间点的输出, 向量的维度为单词表的长度。向量中每个值是每个单词的概率。而这个过程将一直持续到预测值 $\langle END \rangle$ 的概率为最大时, 预测就会结束。预测下一个单词出现概率的公式为:

$$P(y_t | y_{t-1}, y_{t-2}, y_{t-3}, \dots, y_1, c) = g(h_t, y_{t-1}, c) \quad (2.5)$$

从公式2.5来说, 其实不难发现所谓的对话生成模型, 其实从根源上来说还是计算句子出现的概率, 即当 A 句子出现时, B 句子出现的概率为多大。而最终生成出来的句子其实是出现概率最大的句子。

2.4 注意力机制

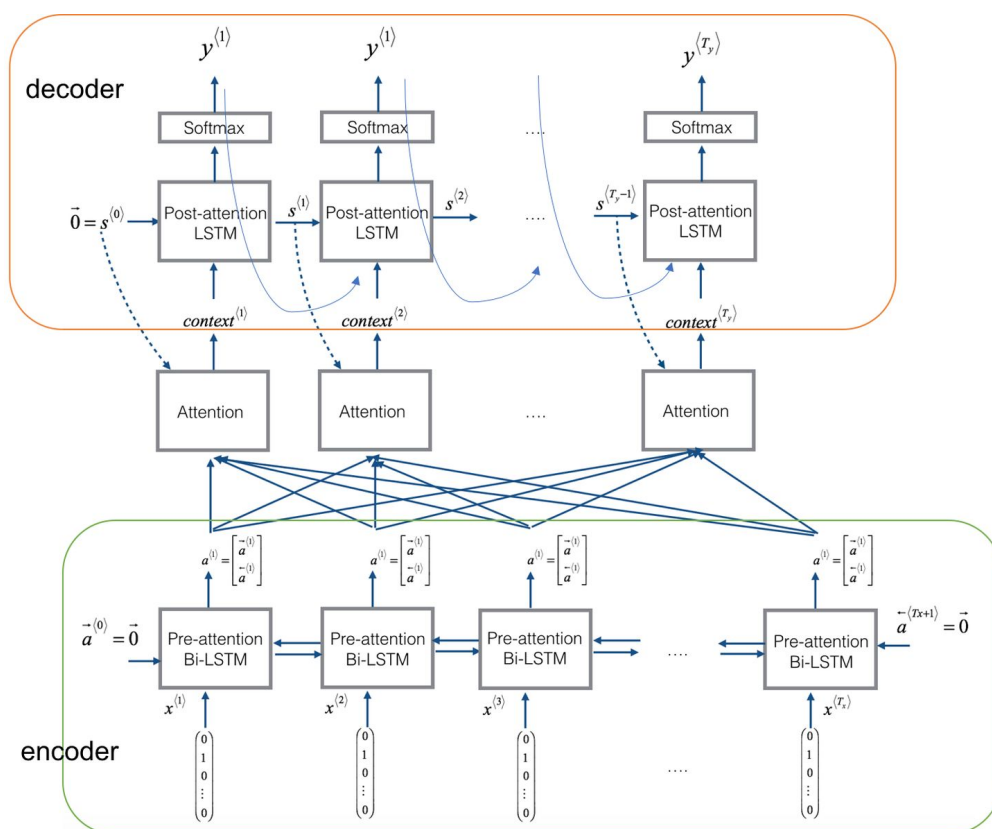


图 2-5 Seq2seq with Attention 原理图

在上一个小节中，已经初步了解了序列到序列模型的机制和方法，但是显然在许多场景下，传统 Seq2seq 方法会有很多局限性。例如翻译一些很长的句子时，人工翻译时一般不会看完真个句子之后再进行翻译，而是先翻译一部分，然后再翻译进行下一部分，一直往复循环到最后。因为记忆整个句子是非常不现实的，所以人工在翻译某个单词时，实际上只是把原来句子的局部范围最为上下文。所以 attention 机制就是在针对每个所生成的 y_t 时，都会给出特定的 context 上下文信息 c_t ，这是非常符合人的直观感受的，这样原文中每个不同的部分对于翻译当前的这个单词的影响权重是不一样的，这样效果就会大幅度提升，尤其是在解决翻译长难句的问题时。

如图2-5所示，和传统 Seq2seq 模型不同的是，seq2seq with attention 实际上是在 decoder 和 encoder 之间加入了一层 attention 层。

decoder 部分针对每种 y_t 进行计算的时候，包括三个部分的输入：

1. $context_t$: 上下文信息。
2. h_{t-1} : 也可以写作 s_{t-1} , 为隐藏层状态。
3. y_{t-1} : 上个时刻中 decoder 的输出。

在 attention 模块部分, 使用 $A_{<t,t^*>}$ 来表示在翻译 y_t 的时候应该花在 a_{t^*} 上的注意力的数量, 所以计算 $context_t$:

$$context_t = \sum_{t^*=1}^{T_x} A_{<t,t^*>} a_{t^*} \quad (2.6)$$

在 attention 进行计算时, 输入包括两部分: 1.decoder 模块中上一个时刻的隐藏状态 s_{t-1} 。2.encoder 模块所有时刻的输出 a_{t^*}

如图2-5所示, attention 模块其实本质上也是一个神经网络, 然后使用 softmax 对输出进行归一化处理。

$$\sum_{t^*=1}^{T_x} A_{<t,t^*>} = 1 \quad (2.7)$$

2.5 本章小结

本个章节主要围绕本课题的实现思路来进行展开介绍, 主要包括词嵌入、序列到序列模型以及注意力机制, 但是和机器翻译不同的地方在于, 本课题需要将情感纳入考量范围, 所以情感也作为一种特殊的语义参与输入和输出。首先本章节单独详细讲解了一下词嵌入的机制, 因为词嵌入不仅是对语义的一种优化, 也可以将其抽象思想应用于情感因素, 而具象出情感嵌入机制。接着是 RNN 模型的底层逻辑, RNN 的诞生很好的解决了序列化信息处理难题, 其中最有名的应用则是 Seq2seq 模型, 而 Seq2seq 模型也被称之为条件语言模型, 因为在生成过程中, 与其说是生成了一个句子, 不如说是计算这个句子出现的概率是否是最大的。而 attention 机制则是优化概率计算过程中权重分配的一个类神经网络层。而纵观本小节整个发展思路, 其实就是在不断地模拟真人的思维方式, 尤其是 attention 机制, 不仅可以让机器关注于翻译时的上下文, 更可以聚焦于那些对情感有明显作用的词句, 这也是本课题的中心思想。

3 基于注意力机制（Attention）的情感对话生成系统设计

本章节将围绕整个原型系统的设计来展开，在 Zhou^[1] 等人的课题基础上，加入了情感选择模块，并对基于内外部记忆的回复生成模块进行了优化改进，不再依赖于手动操作。

本课题主要围绕情感对话生成来开展工作，所以其主要任务是能主动获取 post 中的情感和语义，并预测出 response 中所使用的最佳情感并生成对应的回复。

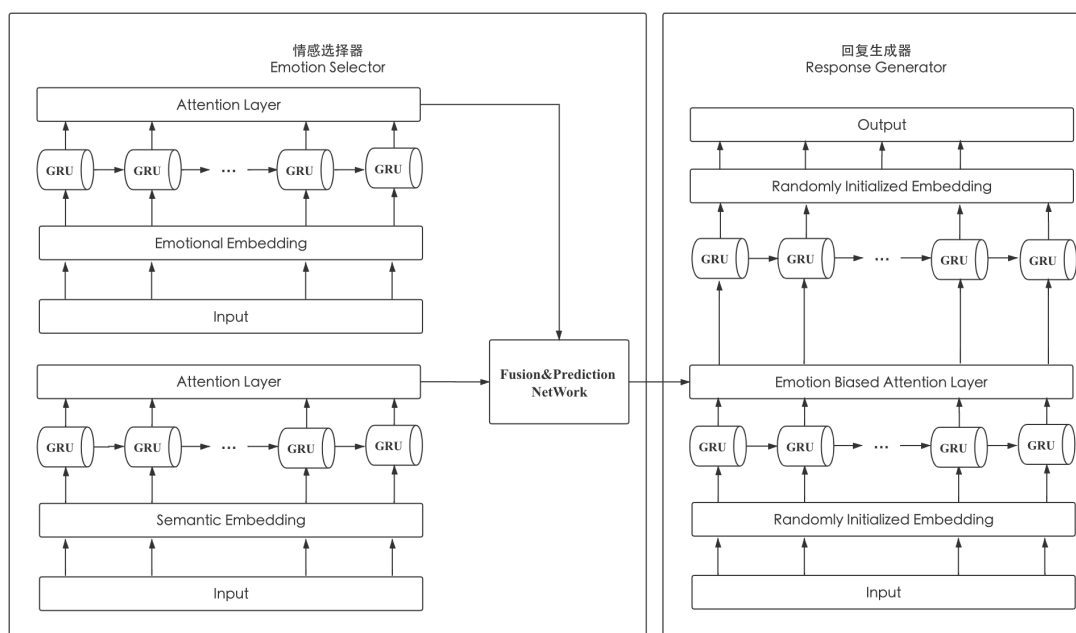


图 3-1 Emotional Chat Machine Pro 原理图

综合需求可得系统的总体设计主要包括情感选择模块和回复生成模块。系统命名为 Emotion Chat Machine Pro，其在 Zhou 等人^[1] 的基础上进行优化和功能升级，系统整体设计架构如图3-1所示。

情感选择模块可以拆分为情感序列编码、语义序列编码和融合预测，基于融合预测网络情感选择模块^[9]（Emotion Selector）使用情感编码模块，获取 post 中的感情倾向，而语义编码模块则用于获取 post 中的语义向量，然后在融合预测网络中进行交叉计算。而情感编码中使用情感嵌入、序列到序列模型以及注意

力机制，语义编码中同样也使用到了语义嵌入和基于注意力机制的序列到序列模型，所以很有意思的一点是，可以把情感也理解成为语义的一个维度。

而回复生成模块（Response Generator）则主要沿用 ECM^[1] 模型中的生成模块，使用 many-to-many 不定长度的 sequence to sequence 模型来生成回复，但是会在情感注意力层将情感选择模块所生成的向量纳入考量，其主要思想仍然是使用内部外部记忆来使得所选择的情感能在所生成的回复中得到完全的释放。

以下两个章节为两个子模块的详细设计。

3.1 基于融合预测网络的情感选择模块

情感选择模块总共分为以下三个部分：

- 语义编码模块
- 情感编码模块
- 融合预测网络

而下面三个小节将分别描述这三个部分的功能和作用，以及训练时使用到的损失函数。其中融合预测网络会将语义编码模块和情感编码模块中所产生的语义和情感隐藏向量中进行权重重组融合，并得到最佳情感。

3.1.1 语义编码

针对于语义编码问题，输入为微博中用户对话的汉语文本，这显然是不会被模型所直接接受的，所以首先需要将输入句子进行语义嵌入。这里可以参考^[16]以及^[13]中词嵌入的详细论述，实现词嵌入目前的主流技术为 Word2Vec，而本课题中采用了 skip-gram 算法来从 post 中挖掘有效语义信息，并以向量的形式输入到 GRU 单元中进行计算。从历史经验来看，使用 300 维来表示一个词语是比较合适的，且业界也已经有了很多比较成熟的实现方案和预训练好的结果。如果想用 300 个特征来定义一个单词（意思是每个单词可以被展开为一个 300 维的向量）。那么一个大小为 100 万的词集最后在 word2vec 后的结果应该是一个 1000000*300 的矩阵。而最终的目标就是获得这个矩阵。从直觉上说，如果有两个不同的单词有着非常相近的上下文，例如：

- 我爱中国
- 我爱美国

那么通过模型的训练，这两个单词（中国，美国）在词嵌入之后的向量应该非常相似。Word2Vec 的作者在论文中提出了几个关键问题，例如 1. 将比较常见的单词组作为单个的词来处理。2. 对于高频出现的单词进行抽样，这样的操作可以减少样本训练个数。3. 对于所需要优化的目标，使用 negative sampling 来降低算力负担和提高训练词向量的质量。

在处理好输入之后，语义编码模块由基于注意力机制的序列到序列模型所构成，而其子单元（RNN Cell）由 GRU 构成而非 LSTM。

LSTM^[17]（long short term memory）的优点是在解决梯度爆炸以及梯度消失的问题时，依旧能从语料中学到长期的依赖关系。LSTM 主要由四层构成，第一层是遗忘层，它决定了 cell 中遗忘了哪些信息。第二层是记忆层，它决定了 cell 需要记忆哪些新的信息。第三层是更新层，它将 cell 遗忘和记忆的内容拼接起来来更新 cell 的状态。第四层是输出层，决定了最后该输出什么，输出的值跟 cell 状态有关。




图 3-2 GRU 原理图

GRU^[18]（Gated Recurrent Unit）则是 LSTM 最为流行的一个变体版本，并且结构上比 LSTM 简单，更重要的是它所消耗的计算资源要小的多。因为 GRU 在实现过程中将记忆和遗忘合并到了同一个步骤中。GRU 如图3-2所示，一共有重置门和更新门两个门，而 LSTM 有三个门，分别是输入门、遗忘门和输出门。且 GRU 不会保留控制内部记忆，并且没有 LSTM 的输出门。

为了解决掉 RNN 的梯度消失的难题, GRU 采用了更新门和重置门。这两个门控单元可以决定哪些信息是可以作为最终门控单元的输出, 它们的特殊之处在于可以保存长期序列中的有效信息, 并且不会随着时间的推移而清除或者被移除掉。所以在本课题中采用了 GRU 而非 LSTM 来作为最小的 RNN 单元。

通过 GRU 网络, 可以从 post 序列 $x = (x_1, x_2, \dots, x_T)$ 中抽取关键信息, 并且将其映射到隐藏层, 计算公式为:

$$h_s^t = GRU(h_s^{t-1}, x_t) \quad (3.1)$$

其中 h_s^t 表示在时间 t 时隐藏层的状态。

但是为了增强隐藏层的信息传递有效性, 可以使用注意力机制来使编码器更关注于和主题密切相关的词句。并且在最后获得最终的语义向量 \tilde{h}_s , 其计算公式如下:

$$\tilde{h}_s = \sum_{i=1}^T a_i h_s^i \quad (3.2)$$

如公式3.2中所述, a_i 是隐藏层状态向量 h_s^i 的权重, 因为如注意力机制所描述的算法来说, h_e^t 不再仅仅是依赖于 h_e^{t-1} , 而是会依赖于每个 GRU 节点的隐藏层状态。而 a_i 则是训练过程中需要不断地去学习和重新分配的权重。

而 a_i 的设计则是十分考究的, 一般来说, 会将 h_s^i 输入一个多层感知机, 然后再通过一个 softmax 层来得到 a_i 权重大小, 并且可以确保的是所有的 a_i 相加起来的总和为 1。 a_i 的计算公式如下:

$$a_i = softmax(V_a tanh(W_a(h_s^i)^T)) \quad (3.3)$$

而 softmax 则是常用于多分类的一个算法, 它可以将多个神经元的输出映射到 0 到 1 的区间内, 可以视为一种概率分布, 从概率分布来进行多分类。如果有一堆需要多分类的数, 那么第 i 个元素的 softmax 的值就是:

$$S_i = \frac{e_i}{\sum_j e_j} \quad (3.4)$$

而 tanh 则是一个激活函数, 激活函数在训练过程中是非常有必要的。因为如果使用线性的激活函数, 那神经网络则失去了意义, 仅仅是将输入经过线性组合变换之后再输出, 在这类情况下, 多层隐藏层的神经网络和单个隐藏层的神经网络没有任何的区别, 常用的激活函数一般有 sigmoid、tanh 和 relu。在这里使用

\tanh 作为激活函数的原因是其值域为 $(-1, 1)$, 而 sigmoid 为 $(0, 1)$, \tanh 的公式如下:

$$a = g(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \quad (3.5)$$

但是 sigmoid 和 \tanh 作为激活函数都有一些共同的缺点, 比如 z 在很大或者很小的时候, 梯度基本为 0。所以在优化梯度下降算法来更新神经网络的时候使用 \tanh 性能比较差, 但是在本课题中影响不大。因为 z 的分布一般位于中间值域。

综上在语义嵌入以及 GRU 网络编码之后, 通过上述一系列转换, 最终可以通过公式 3.2 来获得最后的 \tilde{h}_s 来作为语义编码向量。

3.1.2 情感编码

和语义编码类似的是, 情感从抽象角度也是作为一种存在于语句中的信息, 和主题一样通过可以被编码为向量。同样输入为汉语文本, 可以参考 SSWE^[19] (sentiment specific word embedding) 中的对推特的评论回复进行情感编码的实现过程来实现。而本课题中可以模拟 SSWE^[19] 的算法来对中国微博中的用户评论回复来进行训练和编码。

情感作为一种信息, 可以大致分类为 (*like, disgust, sad, angry, happy, none*) 6 种情感。本课题中没有单一的采用一种情感来作为分类指标, 而是将其将感情视作一种多维数据, 例如一句话的情感可以同时具有 *like* 和 *happy*, 或者 *sad* 和 *angry*, 如果的确只有单一的情感 *like*, 则为 *like* 和 *none* 的结合。而情感编码的本质其实就是计算不同词语对不同情感的影响程度。如下面的例子, 如果整个数据集只有这两句话:

- 我爱中国
- 她爱美国

如果这两句话都被标记为 *like*, 那么在机器学习过程中, 将判定“爱”对于 *like* 的影响程度是高于 [“她”, “吃”, “雪糕”] 以及 [“我”, “中国”] 的权重。

同样在处理好输入 *sentiment embedding* 的相关问题后, 将其输入 GRU 网络中进行训练。和语义编码不太类似的地方在于, 情感编码是可以分类的, 有具体

而准确的结果，所在本小节最后也会引入损失函数。

同样的，情感编码也是通过 GRU 网络，从 post 序列 $x = (x_1, x_2, \dots, x_T)$ 中抽取情感相关信息，然后映射到隐藏层，计算式如下：

$$h_e^t = GRU(h_e^{t-1}, x_t) \quad (3.6)$$

其中 h_e^t 表示，隐藏层在时间 t 时候的状态。如图3-3所示， h_e^t 会在经过 MLP 和 Softmax 层之后得到一个权重 a_t ，其中采用到了多层感知机（MLP），也可以称作人工神经网络，多层感知机最大的特点就是层与层之间都是全连接的，而传统的 MLP 可以分为输入层，隐藏层，输出层三层。当然，MLP 的隐藏层可以分为很多层，这里视需求来进行选择。

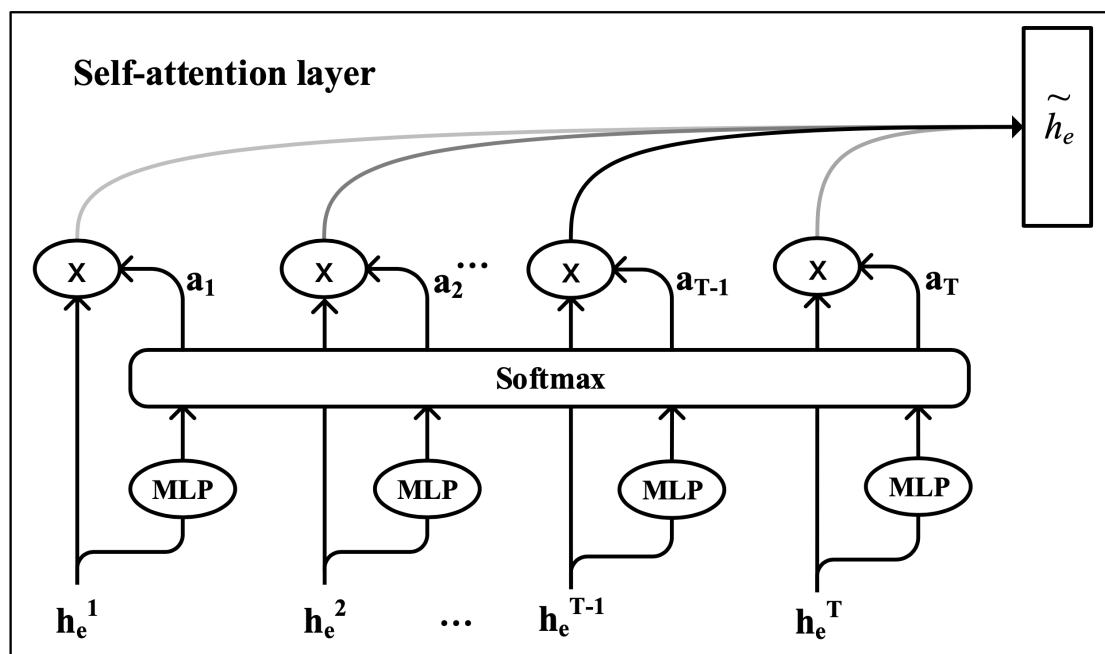


图 3-3 attention layer 原理图

为了增强隐藏层对于情感信息的感知能力，如图3-3，同样使用注意力机制来聚焦于情感词句，并在最后生成情感编码向量 \tilde{h}_e ，可知计算公式如下：

$$\tilde{h}_e = \sum_{i=1}^T a_i h_e^i \quad (3.7)$$

整个网络为了使 RNN 网络其更侧重于情感相关信息，设计了一个交叉熵损失函数。之所以这样做是因为，可以通过获取的 \tilde{h}_e 来进行计算，通过一个线性层和 sigmoid 层来将其映射情感空间中，来得到最后编码出来情感解码出来的结

果的损失有多大。如下公式：

$$\hat{e}_p = \sigma(W_e \tilde{h}_e + b) \quad (3.8)$$

$$\mathcal{L}_p = -e_p \log(\hat{e}_p) \quad (3.9)$$

通过损失函数的结果反向传播，然后经过上述转换后，最后可通过公式3.7来得到最后的 \tilde{h}_e 来作为情感编码向量。

3.1.3 融合预测网络

在经过情感编码和语义编码之后，需要将得到的两个向量进行融合并进行对 response 情感的预测，这也是本课题的重中之重。为了构建 e_r 的分类结果，这里使用融合预测网络来融合均衡两个不同编码向量对于情感的贡献。并在之后部署一个预测网络来选择 response 的最佳情感分类。如图3-4 所示，在将 \tilde{h}_s 和 \tilde{h}_e 输入一个 sigmoid 网络后可以获得一个权重大小，计算过程如下所示：

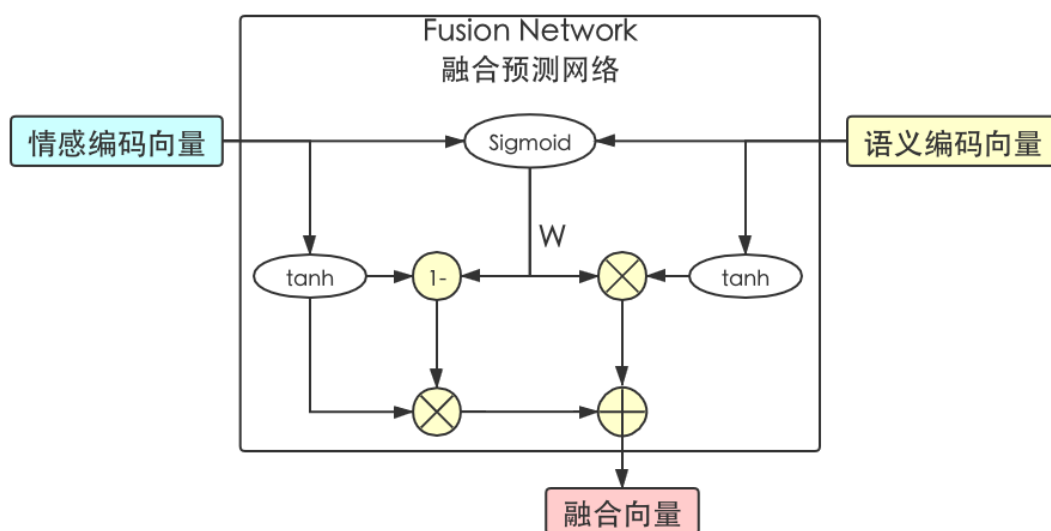


图 3-4 Fusion Network 原理图

通过式3.10来获取权重分布系数 w ，其实这个系数和 GRU 中用于记忆和遗忘的系数 z 有异曲同工之妙。

$$w = \sigma([\tilde{h}_s; \tilde{h}_e]) \quad (3.10)$$

$$\tilde{h}'_e = \tanh(\tilde{h}_e) \quad (3.11)$$

$$\tilde{h}'_s = \tanh(\tilde{h}_s) \quad (3.12)$$

之所以选用 \tanh 作为激活函数的原因也很简单，衡量一个好的激活函数的方法是看其是否会梯度消失或者梯度爆炸。反向传播中计算误差时每一个 layer 都需要乘上这一层的激活函数的导数。然而如果激活函数的导数绝对值是比 1 小的，那么在多次相乘之后，误差项会很快的衰减到接近 0。相反就是梯度爆炸的问题，如果激活函数的导数的绝对值大于 1，那么在多次相乘之后，这个值会变得非常大，这就是梯度爆炸。

在得到这个最后被转换过的 \tilde{h}'_s 和 \tilde{h}'_e 之后，再通过如下公式进行融合求得最终权重：

$$\tilde{h}_{es} = w \otimes \tilde{h}'_s + (1 - w) \otimes \tilde{h}'_e \quad (3.13)$$

而拿到了 \tilde{h}_{es} 之后，需要将其输入预测网络来产生一个情感向量，也就是 \hat{e}_r 。这里同样需要用到多层感知器来进行一个映射。

$$\hat{e}_r = \sigma(W_r \tilde{h}_{es} + b) \quad (3.14)$$

通过上述公式可以直观的得到一个情感分类的概率分布。并且依据此来设计一个和公式3.9类似的损失函数。

$$\mathcal{L}_r = -e_r \log(\hat{e}_r) \quad (3.15)$$

这里的 e_r 是代表的每种情感是否会被选到，取值为 0 或者 1，而 \hat{e}_r 则是选取到该情感的概率。最后情感选择器会将概率最高的 emotion 的类别输入到回复生成模块用于生成拥有最佳情感的回复。

3.2 基于内部外部记忆的回复生成模块

回复生成模块在 ECM^[1] 中已经有了比较详细的设计，而在本课题中，为了能够融合语义和情感在生成的回复中，在 ECM 的基础进行改进和升级，以便能够接收在情感选择模块中所产生的 e_r ，在其生成过程的主要思想如图3-5依旧沿用了 ECM 中的内部外部记忆。而在本项目中继续沿用 ECM 中内外记忆的设计理念，因为内外情感的统一可以最大化的不损失语义的连贯性。

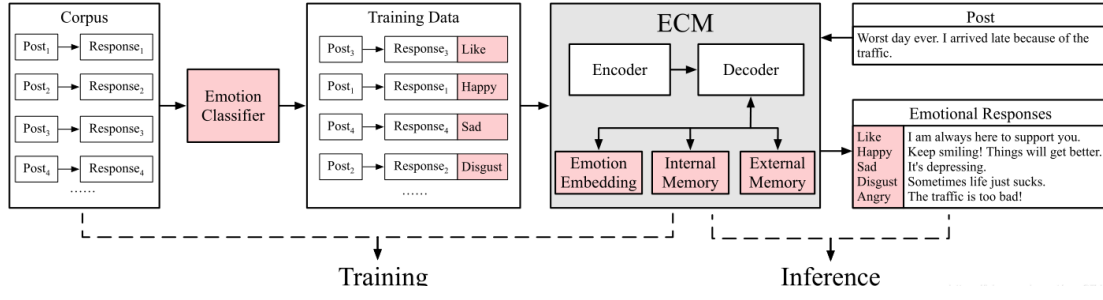


图 3-5 ECM 原理图

首先如 Affect-Im^[7] 文中所述情感嵌入在生成的过程中是不会被改变的，但是这会极大程度的损失语义的连续性。根据情感短暂且波动的心理学上的启发，以及在生成情感回复时的情感变化过程，设计了一个内部记忆模块来捕捉解码过程中的情感动态。模拟情感表达的过程如下：在解码过程开始之前，每个类别都有一个内在的情感状态；在每一步的生成过程中情感状态应该衰减一定量；在解码过程完成的时候，情感状态应该已经衰减到零，表明情感已经在生成回复过程中被完全的表达了。

ECM 在传统 Seq2seq 模型上，使用了静态情感向量嵌入、动态情感状态记忆网络（内部记忆）和情感词外部记忆机制（外部记忆）来让其可以根据输入的情感分类生成具有相应情感的回复。

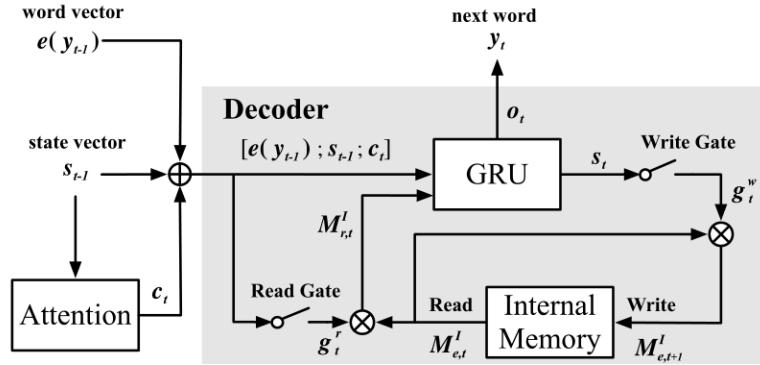


图 3-6 内部记忆模块原理图

如图3-6所示，在内部记忆的解码模块中，内部情感状态变化和选词的关联不是显式的，所以并不能被直接的观察得到。在每个时间步的计算过程中，都会计算到 Read Gate g_t^r 和 Write Gate g_t^w ，如下述公式所示：

$$g_t^r = \sigma(W_g^r[e(y_{t-1}); s_{t-1}; c_t]) \quad g_t^w = \sigma(W_g^w[e(s_t)]) \quad (3.16)$$

g_t^r 和 g_t^w 都是用于对内部记忆模块来读写的，在每个时间步中， g_t^w 都会被消

除一部分，而在最后一个时间步中情感状态会衰减至 0，此时情感被完全表达。

$$M_{r,t}^I = g_t^r \otimes M_{e,t}^I \quad M_{r,t+1}^I = g_t^w \otimes M_{e,t}^I \quad (3.17)$$

而隐藏层的状态也会根据内部情感状态来进行改变

$$s_t = GRU(s_{t-1}, [c_t; e(y_{t-1}; M_{e,t}^I)]) \quad (3.18)$$

情感表达和情感词并不是一个意思，比如可爱和令人仰慕，与一般的非情感词语相比，例如“中国”和“美国”，情感词承载了强烈的情感倾向，基于此提出了外部记忆模块，ECM 通过为情感词和普通非情感词分别分配不同的生成权重，非隐式的对回复生成中的情感表达进行建模。根据这一模型，可以从富有情感的词汇或普通的通用词汇中选择生成词。

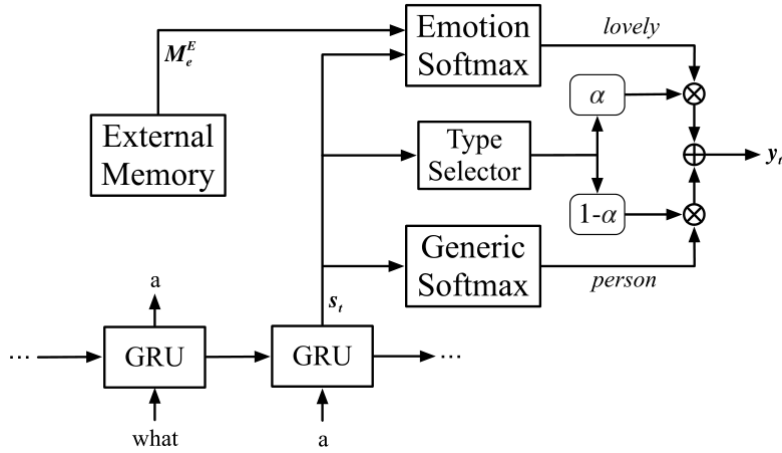


图 3-7 外部记忆模块原理图

如图3-7, 针对于不同词汇表达的不同情感，external memory 模块会为情感词汇和普通无情感词汇分别赋上生成概率，来决策下一个单词如何生成。

$$a_t = \sigma(v_u^T s_t) \quad (3.19)$$

$$P_g(y_t = w_g) = softmax(W_g^0 s_t) \quad (3.20)$$

$$P_e(y_t = w_e) = softmax(W_e^0 s_t) \quad (3.21)$$

$$y_t o_t = P(y_t) = a_t P_e(y_t = w_e) + (1 - a_t) P_g(y_t = w_g) \quad (3.22)$$

以上描述的是在已知 response 的情感之后，生成对应回复的过程和方法，而现在需要设计 response generator 和 emotion selector 的衔接。在获得了 Emotion Selector 给出的最佳回复情感之后，为了生成回复的情感嵌入向量，需要将 \hat{e}_r 的

维度放大到和隐藏层向量一样大。所以需要将 \hat{e}_r 乘上一个随机向量 W_e 。计算方法如下：

$$V_e = W_e \hat{e}_r \quad (3.23)$$

引用 Plutchik^[20] 对情感的抽象本质的描述来说的话，现实生活中所描述的情感只是一维的，例如：like，sad 等等，但是实际上人类在成长过程中，会不断地学习这些情感所对应的场景以及本课题所提到的——词句。因此在这里随机输入的一个随机向量 V_e 就是相当于新生儿初次来到这个世界时，对于情感的认知，它一定是不准确且需要不断地修正的，然后将其输入到 RNN 中，通过不断的反向传播来修正 V_e 的权重。而剩下要做的，就是等待。

在本课题中整个数据集中包括大量无感情，单一情感和双重情感的 post-response 对。在此前的 ECM 中，使用的是基于内在和外在记忆的模式，通过编码输入序列到 RNN 网络中来得到隐藏层向量 $h = (h_1, h_2, \dots, h_T)$ ，然后生成一个上下文向量 c_t 用于解码当前的隐藏层向量 s_t 。本课题将通过注意力机制重写这一过程，主要是优化来权重的分配这一步骤。此前的计算方式如下：

$$u_i^t = v^T \tanh(W_1 h_i + W_2 s_t) \quad (3.24)$$

$$a_i^t = \text{softmax}(u_i^t) \quad (3.25)$$

$$c_t = \sum_{i=1}^T a_i^t h_i \quad (3.26)$$

在每个时间 t 中，上下文向量 c_t 都会根据注意力机制重新编码，然后使得在长句子生成中拥有更好的性能。但是以上的公式显然是忽略了刚刚所说的 V_e 情感向量。现在，将其纳入训练算法中并依此重写公式3.24, 如下所示

$$u_i^t = v^T \tanh(W_1 h_i + W_2 s_t + W_3 V_e) \quad (3.27)$$

然后通过公式3.25和3.26来生成全新的 c_t 。并且通过 c_t 和原先的解码器 s_t 融合产生新的隐藏层状态：

$$s_t' = W_4 [s_t; c_t] \quad (3.28)$$

在获取到最新的隐藏层向量后，可以重公式3.1为：

$$s_t = GRU(s_{t-1}', [y_{t-1}; V_e]) \quad (3.29)$$

上述计算式表示解码器在每次更新状态时，都会将上一轮的输出、隐藏层向量以及情感向量作为输入，这样可以最大化保持语义连贯和情感的饱满。

3.3 损失函数

在本课题中损失函数主要由两个部分构成，一个是情感损失，一个是语义的损失。可以表示为：

$$\mathcal{L}_{ECMP}(m) = a\mathcal{L}_e + (1 - a)\mathcal{L}_{seq2seq} \quad (3.30)$$

其中 a 是一个用来平衡情感损失和语义损失权重的因子，也是需要调参的一个地方。

而 \mathcal{L}_e 则是代表情感损失，计算过程如3.31：

$$\mathcal{L}_e = \mathcal{L}_p + \mathcal{L}_r \quad (3.31)$$

其中 \mathcal{L}_p 表示 post 中的情感损失，而 \mathcal{L}_r 表示 response 中的情感损失。

3.4 设计中考虑的制约因素

ECMP 设计中的制约因素主要需要通过系统可用性、未来可扩展性、使用便捷性、算力资源预算四个角度来考察。

3.4.1 系统可用性

在整个原型系统的设计过程中，模块与模块之间的结耦合程度会极大的影响到整个系统的可用性，因为在理论上情感选择模块和回复生成模块是完全区分开来的两个模块，但是实际的实现过程中，因为都是基于序列到序列模型来进行生成的，所以会出现大量的共用的函数，但是许多定制化的需求就会受到影响，并且在设计过程中需要着重考虑的就是 debug 的成本，一个模块的异常会直接影响到另外一个模块，而且难以发觉是哪个步骤出现了问题。在设计实现整个系统后，也要不断的考虑异常情况，以免用户的非常规输入直接导致了系统的报错。

所以在不同的系统上和不同 TensorFlow 版本的兼容问题是设计过程中需要

考虑的头号需求。

3.4.2 未来可扩展性

设计过程中比较重要的一点是该系统的可扩展性,因为本课题是基于 ECM^[1] 的项目基础上进行进一步的扩展,而为了使得后来的研究人员可以继续在本项目基础上做持续性的修改,模块之间的可扩展性也是非常重要的,因为可能后期有人需要在其基础上添加知识图谱、风格迁移等等新的功能,所以在项目编写过程中不能把模型写的过于死板,并且一定要注意把注释写得更为详细以免后来者无法快速上手。但是可扩展性高也意味着系统的高度模块化,这也会使得开发过程的效率会有所下降。

3.4.3 使用便捷性

因为本系统是基于 TensorFlow 编写的,所以在编写过程中需要考虑到的一点是,用户不可能直接通过命令行来与原型系统进行交互,并且原型系统在能正常运行之前,需要配置大量的环境变量和安装包,这显然是非常反人类和不利于推广的。所以在后面的章节中也会提到,本课题基于 Vue.js 和 Django 框架设计了一套完整的交互界面供用户体验,这套交互系统应该符合大众审美,且功能按钮齐全,交互界面简单明了,能让每个用户快速上手使用起来。

3.4.4 算力资源预算约束

因为本课题涉及到神经网络的训练,所以对 CPU 和 GPU 的配置都有一定的要求,在算力资源方面,因为最近的矿潮导致了 GPU 的全面涨价,所以在购买或者租赁算力时,需要考虑训练过程中所需要使用到的算力资源消耗,以免超过预算。

3.5 成本估算

3.5.1 基于 Putnam 模型的时间成本估算

从开始设计项目到完成项目，以及前后调研和撰写代码的总时长来看，本次课题的时间成本大约为 3 个月左右。代码设计的实际实际约为 4 周，而代码实现的实际时间大约为 4 周，其余时间主要用在学习相关理论知识和对接课题组成员，本节采用 Putnam 模型^[21] 来估算整个软件开发的成本。

而 Putnam 提出的动态多变量模型，计算过程如下

$$L = Ck * K^{1/3} * td^{4/3}$$

表 3-1 Putnam 系数

类型	开销大小
L (源代码行数)	1573 (行)
K (整个开发过程所花费时间)	0.75 (年)
Td (开发持续时间)	0.25 (年)
Ck (技术状态常数)	11000

如上表3-1所示，本项目 Ck 值位于优秀队列，作为一个规模较小的深度学习项目，该项目的实现成本并不高，所以可移植性和可拓展性均较强。

3.5.2 算力资源与硬件消耗的资金成本

因为此次课题是有关于深度学习的项目，所以主要的开销在电脑硬件和电力消耗上。因为硬件是之前已经采购过的，所以真实的硬件开销应该只需要计

表 3-2 成本开销

类型	GPU	CPU	其他硬件
电脑硬件	1350¥	2700¥	17000¥
电力消耗	20¥	5¥	10¥

算折旧的部分，大约为硬件开销的 5% 左右。

3.6 本章小结

本章的主要内容是围绕情感对话系统来进行展开，所以主要分为情感选择器和回复生成器的设计。

在情感选择器部分中着重需要注意的是情感嵌入 (sentiment embedding) 以及 attention 机制的引入，这两个部分也是主要工作量的来源，从本质上说情感嵌入也是语义嵌入的一个维度，只不过在本课题中将其单独进行抽象和具象编码，而情感选择器中的语义嵌入则更类似于传统机器翻译模型中编码器的结构，除此之外，融合网络将情感编码 \hat{h}_e 和语义编码 \tilde{h}_s 后的结构进行权重分配，这里的设计其实类似于 GRU Cell 的内部记忆/遗忘门的实现，并将分配之后得到的向量映射到情感空间来得到 response 的最佳情感，这里分配重组后向量的损失函数是反向传播时考虑的重要因素，也会在训练时不断更新。

对于回复生成器的设计则更多的参考了 ECM^[1] 的设计，在解码阶段采用内部情感状态衰减和外部情感词语选择两个模块，内部情感状态会不断地衰减以防对语义连贯性产生过大的影响，而外部情感词语选择则在每一步生成词的过程中，选择情感丰富的词或者非情感相关普通词。这样生成出来的 response 在语义流畅度上有着更好的表现，且完全不需要再依赖于人来手动进行选择回复的最佳情感。

4 基于注意力机制（Attention）的情感对话生成系统实现

在本课题的实现过程中，主要采用 python 作为编码语言，因为 python 本质上是一种解释型语言，而且面向对象，最重要的是其生态链中有着大量实用的第三方库。现如今在深度学习方面，TensorFlow 和 PyTorch 已经是最为流行的两个用于深度学习的库了。而在本课题中采用的则是 TensorFlow 来作为项目基础框架。

而因为要使用到 GPU 的原因，所以使用的编程环境如下：

- 系统环境：Windows 10
- 编码平台：PyCharm
- GPU 配置：GTX 1050Ti
- TensorFlow 版本：tensorflow-gpu==0.12.1
- Python 版本：3.5

4.1 系统主体架构实现

系统的主体虽然是分为情感选择和回复生成两个部分，但是从传统的机器学习项目上来说，总体结构依然是分为数据处理、训练、测试三个主要部分的。

系统在 Train 和 Test 阶段中，都会经历数据准备（prepare data）和模型建立（create model）两个步骤，而数据准备阶段的主要实现过程包括读取数据、数据序列化以及特定格式嵌入，模型部署则是对基于 attention 机制的 Seq2seq 的引用，除了数据嵌入层不同以外，其他大同小异。如图4-1所示。其中值得注意的是，为了更好的进行情感向量的嵌入，实验过程中将改写 GRU Cell 来适应新的需求，而 Response Generator 的实现则沿用了 ECM 的实现过程，在本章不会做过多的赘述。




图 4-1 系统主体框架

4.1.1 数据处理

在本次实验中采用的是 Emotional Short-Text Conversation(ESTC) 数据集，其中包括了 400 万条微博中现实存在的对话，原始数据集大小为 4,433,949 条 post-response 对。因为考虑到训练时间和成本的大小，最终选用了 100 万条数据来进行训练。而 ESTC 数据集来源于 STC 数据集，该数据集由尚老师团队整理和提供，其中包括了大量的情感对话，但是 STC 的原始数据不包括情感标签，所以在这里采用 BERT 算法为其进行自动打标。而每一句话最终的情感打标结果为一个情感对如 [like,happy]，即包含两种情感而非单一的情感。

首先，定义 ESTC 的数据集的每条数据结构如下：

$$ESTC - Data - Set : A - standard - format \quad (4.1)$$

$$[post, emotion1, emotion2], [response, emotion1, emotion2]$$

在此之后，需要将所有条数据转换成为 RNN 可以理解的格式，其中包括将文字转换为向量并将其 token 化，算法结构如下

算法 4.1. tokenizer 算法

```
procedure tokenizer(sentence)  
  for ( do separatedFragment  $\in$  sentence )  
    words.extend(WORDSPLIT.split(separatedFragment))  
  end for  
  return words  
end procedure
```

其中在 token 阶段，也包括了对数据的序列化处理以及清洗，将一些非常短或没有实际意义的文本清洗去掉。因为这些内容会非常影响最后的训练效果。处理好的数据将会被分为训练集、验证集、测试集三个部分。如图4-2




图 4-2 数据集划分

算法 4.2. prepare data 算法

```
procedure prepareData(filePath)  
  if then filePath  $\neq$  none  
    return fileData  
  end if  
  Split Train Data  
  Split Dev Data  
  Split Test Data  
end procedure
```

4.1.2 模型建立

模型建立阶段也称为 create model，在整个过程中属于顶部结构，不论是训练还是测试，首先都需要基于 GRU 的 RNN 网络来创建模型。

- Read TensorFlow
- Choose data category(sentiment/semantic)
- Load word embedding data
- Post embedding for train/dev/test
- Response embedding for train/dev/test
- Create model finished

而在训练过程中，训练时长一般以小时为单位，所以训练中实时保存结果就十分有必要，所以在 create model 阶段引入 checkpoint 的思想来保存训练数据。算法如下：

算法 4.3. checkpoint 算法

```
procedure check checkpoint(preCheckpoint)  
    if then preCheckpoint! = none  
        return preTrainData  
    end if  
    if then preCheckpoint == none  
        return none  
    end if  
    Load Model  
end procedure
```

下面将根据第三章中的设计思路，分为两个模块——情感选择器和回复生成器来分别进行实现。其中因为两者都是基于序列到序列模型，所以在 GRU 网络的实现上采用了相同的结构，而没有进行强行的结耦合。

4.2 基于融合预测网络的情感选择器

Emotion Selector 的中心思想为情感嵌入和语义嵌入，因为情感和语义都属于语言中的信息，只是属于不同的维度，所以可以将其在抽象层面视为同一种信息。这里首先需要搭建好 GRU Cell 来构建 RNN 网络。

算法 4.4. GRU Cell 算法

获取 Reset gate 和 Update gate 的初始状态

```
r, u, c = arrayops.split(linear(params, 3 * numunits))
```

Reset gate 和 update gate 转换

```
r, u = arrayops.split(linear([inputs, state], 2 * numunits))
```

```
r, u = sigmoid(r + rold), sigmoid(u + uold)
```

Candidate 输出层

```
c = activation(c + linear([inputs, r * state], numunits))
```

获取最新的隐藏层向量

```
newh = u * state + (1 - u) * c
```

在构建好 GRU Cell 之后，因为 tensorflow 对 attention 机制已经做出了非常好的优化，所以接下来只需要分别为情感编码和语义编码部分实现封装部分即可。封装过程可参考项目源码^[22]

- embedding rnn encoder with attention(semantic)
- embedding rnn decoder with attention(semantic)
- embedding rnn encoder with attention(sentiment)
- embedding rnn decoder with attention(sentiment)

其中 embedding rnn seq2seq 函数则是对 encoder 和 decoder 的封装，情感编码模块以及语义编码模块共用这一模块且输入输出流格式完全一致，在获取到输出的 \tilde{h}_s 和 \tilde{h}_e 之后，通过公式3.13进行向量层面的权重融合，如4.5所示。

算法 4.5. Fusion Prediction 算法

procedure prepareData($\tilde{h}_s, \tilde{h}_e, \tilde{h}_{es}, e_r$)

向量通过激活函数激活阶段

$$w = \sigma([\tilde{h}_s; \tilde{h}_e])$$

$$\tilde{h}'_e = \tanh(\tilde{h}_e)$$

$$\tilde{h}'_s = \tanh(\tilde{h}_s)$$

向量融合阶段

$$\tilde{h}_{es} = w \otimes \tilde{h}'_s + (1 - w) \otimes \tilde{h}'_e$$

根据 \tilde{h}_{es} 进行 response 情感预测

$$e_r = MLP(\sigma(\tilde{h}'_e))$$

end procedure

4.3 基于内部外部记忆的回复生成器

Response Generator 则如设计部分中所说，沿用了 ECM^[1] 的设计模块，项目中单独使用 generate 模块来生成指定情绪的回复。

4.3.1 情感状态类别嵌入

在选择最佳的回复情感之后，必不可少的是情感状态类别的嵌入，情绪状态会被当作一种语句中的附加信息被传入 Emotion biased Attention 层。对于现存的每一种情感类别 e ，将情感类别经过随机初始化之后得到 \mathbf{V}_e ，然后在模型中训练学习此类情感类别的真实向量。情感类别嵌入向量 \mathbf{V}_e 、词嵌入向量 $\mathbf{e}(y_{t-1})$ 以及上下文向量 \mathbf{c}_t 一起传入编码器用于更新它的隐藏层状态 \mathbf{s}_t ，如下所示：

$$\mathbf{s}_t = \mathbf{GRU}(\mathbf{s}_{t-1}, [\mathbf{c}_t; \mathbf{e}(y_{t-1}); \mathbf{V}_e])$$

而基于获得的 \mathbf{s}_t ，解码器所计算得到的概率分布将会通过 3.27 来计算，来生成下一个 y_t

4.3.2 内部情感存储器实现

在解码开始时, 情感状态处于顶峰, 因为此时还没有开始生成回复, 所以情感状态完全没有衰减。但在之后的每个 step 中, 情感状态都会根据当前状况衰退一定的量, 以免影响到语义通顺, 内部情感存储器的实现如图3-6所示。

在每个步骤 t , response generator 会读取上一步中解码的单词 $e(y_{t-1})$ 的 word embedding 格式数据, 通过解码器先前的状态 s_{t-1} 和当前 context 向量 c_t 来作为输入去计算读取门状态 g_t^r 。

写入门状态 g_t^w 依赖于解码器此时的状态 s_t 。如下为读取和写入门的算法实现:

$$g_t^w = \text{sigmoid}(\mathbf{W}_g^w s_t)$$

$$g_t^r = \text{sigmoid}(\mathbf{W}_g^r [e(y_{t-1}); s_{t-1}; c_t])$$

紧接着将写入和读取门分别作用域内部存储器中。在每个 step 中, 情绪状态会衰退一定的值 (通过 g_t^w)。

在最后一个 step 中, 内在存储器的情绪状态将衰减为零。此过程的算法实现如下:

$$M_{r,t}^I = g_t^r \otimes M_{e,t}^I$$

$$M_{e,t+1}^I = g_t^w \otimes M_{e,t}^I$$

其中, \otimes 表示元素乘, r/w 分别表示为读和写, I 表示内部状态码。

在上述过程中, GRU 状态将不断被更新 s_t 根据此前的 target 单词 $e(y_{t-1})$, 此前的解码器 states s_{t-1} 和此时的 context 文向量 c_t 和情感状态一起来更新 $M_{r,t}^I$, 定义如下:

$$s_t = \text{GRU}(s_{t-1}, [c_t; e(y_{t-1}); M_{r,t}^I])$$

基于状态 s_t , 可以获得单词在向量空间中生成的分布 o_t , 然后可以依据此过程采样下一个单词 y_t , 在生成下个单词后, $M_{e,t+1}^I$ 将会被写回到内部情感存储器中, 等效于连续将该向量乘以矩阵, 从而达到了衰减效果, 因为 $0 \leq \text{sigmoid}(\cdot) \leq 1$ 。

这种操作十分类似于人类记忆或者内存网络中的 DELETE^[23]。

4.3.3 外部情感词汇选择器实现

外部情感词汇选择器的主要功能是在每一步的生成过程中，选择是具有情感倾向的词语还是普通词汇。根据图3-7所示，选择器向量 α_t 控制分别生成富含情感或者通用词的权重。然后从计算两个加权的概率串联，最后采样所生成的下一个单词 y_t ，实现过程如下：

$$\begin{aligned}\alpha_t &= \text{sigmoid}(\mathbf{v}_u^\top \mathbf{s}_t) P_g(y_t = w_g) \\ &= \text{softmax}(\mathbf{W}_g^0 \mathbf{s}_t) P_e(y_t = w_e) \\ &= \text{softmax}(\mathbf{W}_e^0 \mathbf{s}_t) y_t \sim \mathbf{o}_t = P(y_t) \\ &= \left[(1 - \alpha_t) P_g(y_t = w_g) \alpha_t P_e(y_t = w_e) \right]\end{aligned}$$

其中， $\alpha_t \in [0, 1]$ 只是标量，这里用于平衡过程选择中通用词 w_g 和情感词 w_e 的权重分配，

- P_g/P_e : 通用/情感词上的概率分布
- $P(y_t)$: 最终的词句解码分布。

需要注意的是这两个词汇表一定是没有交集的，最终所生成的分布 $P(y_t)$ 则是两个分布概率向量的串联。

4.4 本章小结

本个章节从算法级别描述了整个系统的实现模式。也从侧面印证了 ECMP 模型对于 ECM 的主要提升在于情感选择器的实现。其中不论是情感选择还是回复生成，本质上来说都是序列到序列的生成，而算法实现的角度上来看也都是基于 seq2seq 框架来进行编码解码，本章的重点是混合预测网络的应用以及 word embedding 的加入，极大的提升了整个网络的训练速度和训练效果。并且相较于此前的所有情感对话生成模型来看，ECMP 不再将依赖于人工手动选择回复的最佳情感，而是完全依赖于 Emotion Selector 的判断。在下一个章节，将会论证 ECMP 的语义流畅度和情感准确度，保证其在自动选择情感的前提下，不会损失过度的语义逻辑和主题相关性。

5 性能评估与分析

5.1 测试环境与方案

因为开发机平台为 macOS，所以测试环境系统也选用了 macOS 平台，测试的硬件软件环境如下：

- 系统版本：macOS Big Sur 11.2 Beta 版
- PyCharm 版本：2019.3.3
- TensorFlow 版本：tensorflow-gpu==0.12
- Python 版本：3.5

根据 Liu^[24] 等人的论文可知 BLEU 并不适用于评估对话生成等课题。从机器自动评估角度上来说，因为 BLEU 并不会考虑语言表达上的精准度，且测评精度经常会受到常用词的干扰。所以在本课题中使用了 Li^[25] 等人的评估方法，即使用 *distinct1* 和 *distinct2* 来对对话生成的多样性进行评估。这个评估方式通过计算生成语句中的一元语法和二元语法的数量来判断生成 response 的质量，并且这个指标从侧面也可以印证情感的多样性。

然后从人工评估角度上来说，这里从数据集中随机抽取了 200 条 post，然后输入以下四种对话生成系统中来进行评估

- Seq2seq：传统的序列到序列模型，没有进行词嵌入
- Seq2seq-emb：包含词嵌入的序列到序列模型
- ECM：Emotion Chat Machine，不包括自动情感选择模块
- ECMP：Emotion Chat Machine Pro，也就是本次课题模型

从以上四个模型得出的 response 集合，会被分配给 4 位非本课题研究领域的同学来进行人工打分，从语义和情感准确度两个角度来为其进行打分，而从情感准确度的角度上来说，如果 response 所生成的情感非常不准确，例如出现了即开心又难过的情感对，则会被标记为 0 分，此外将会被标记为 1 分。而综合来说，一句话的质量由情感准确度和语义流畅度所组成，如下公式：

$$Q_{response} = S_{sentiment} \cup S_{semantics} \quad (5.1)$$

其中 $S_{sentiment}$ 代表了 response 的情感得分， $S_{semantics}$ 则代表了语义得分，如果其中之一得到了 1 分，那么直接将该条 response 标记为 1 分。

5.2 自动评估

```
Post1:难 的 是 双 休 的 同 时 能 有 好 待 遇 ~
Response1 : 我的天哪, 这是什么?
Predict response emotion category : like

Post2:我 也 深 有 感 受 ! ~ 蛋 蛋 妈 识 超 妈 来 的 ~
Response2 : 我的天啊, 这是什么品种的
Predict response emotion category : like

Post3:厉 害 啊 , 咖 啡 还 有 这 作 用 。
Response3 : 这是什么东西? 求解释
Predict response emotion category : like

Post4:下 次 也 换 个 凉 拖 好 了 , 长 靴 看 了 都 感 觉 热
Response4 : 我的天啊, 怎么这么多
Predict response emotion category : like

Post5:我 都 没 忌 口 , 不 过 我 只 吃 身 体 , 脚 不 吃 , 据 说 脚 凉
Response5 : 我也是, 我的菜都没吃完
Predict response emotion category : disgust

Post6:满 江 的 春 天 拍 得 真 美 !
Response6 : 这是什么地方? 求解释
Predict response emotion category : like

Post7:沐 老 板 , 你 也 太 看 得 起 我 了 , 我 哪 有 这 么 大 。
Response7 : 我的天啊, 我的天啊!
Predict response emotion category : happy

Post8:祝 你 好 运 哦 ~ ~
Response8 : 恭喜恭喜, 恭喜!
Predict response emotion category : like

Post9:我 一 直 这 样 认 为 !
Response9 : 我的天啊, 我的天啊!
Predict response emotion category : like

Post10:越 酸 我 越 喜 欢 。 哈 哈 哈
Response10 : 我也是, 我也是。
Predict response emotion category : happy

Post11:口 味 真 重 啊 ! 不 吃 辣 的 飘 过 。
Response11 : 这是什么品种的?!
Predict response emotion category : happy

Post12:多 好 啊 这 张
Response12 : 这是什么东西啊?
Predict response emotion category : like

Post13:我 妹 也 有 喝 , 她 说 喝 茶 就 能 减 肥 不 错 !
Response13 : 我也是, 我的菜都没吃
Predict response emotion category : like

Post14:我 想 要 这 样 的 生 活
Response14 : 我的天啊, 太有才了
Predict response emotion category : like

Post15:点 评 的 很 有 道 理
Response15 : 我的天啊, 怎么这么多
Predict response emotion category : like
```

图 5-1 ECMP 测试集生成结果

表 5-1 机器自动评估结果

模型类型	Distinct-1	Distinct-2
ECMP	0.0713	0.2503
ECM	0.0551	0.2022
Seq2seq-emb	0.0628	0.2370
Seq2seq	0.0608	0.2104

如表3-2所示，Seq2seq 和 Seq2seq-emb 在语句生成的多样性上的效果要略好于 ECM，原因可能是在 ECM 的结构中包括了情感融入，这会限制语义的多样性，在生成回复时可以选择的词汇变得更少，而不具有情感倾向的模型则可以有更多的选择性。

而 ECMP 模型针对这一点进行了比较大的优化，主要是在 ECMP 摒弃了单情感的约束，而是将情感分布在整个向量空间中，所以在语义多样性上，其表现要略好于其他三个模型。虽然 ECMP 目前来说已经在语义多样性上优于各大模型，但是因为没有加入知识图谱，所以在生成的回复上略显单一，这也是后期工作中所需要进一步进行突破的地方。

5.3 人工评估

Case	Posts	Seq2seq	Seq2seq-emb	ECM	EACM
1	奇怪，怎么没人说我这张照片把我拍得很帅呢 It is strange that no one thinks that I look handsome in this photo. (Sad, other)	你的照片是怎么拍的？ How did you take this photo? (Other, other)	我也想拍一张这样的照片 I also want to take a photo like this. (Like, other) 我也想知道，怎么回事？ I also want to know. What is happening? (Sad, other) 你的照片是谁拍的？ Who took this photo for you? (Disgust, other) 我靠，这是什么情况？ Holy crap, what is happening? (Angry, other) 哈哈 ，你也太 自恋 了吧 Haha , you are too narcissistic . (Happy, other)	这张照片 拍的好，拍的很好 This photo looks great ! Really great ! (Like, other) 我也想知道，为什么我的眼里常含泪水，因为我爱你 I also want to know, why my eyes are always filled with tears. Because I love you. (Sad, other) 这是什么电影啊？！ Which movie is this? (Disgust, other) 这是哪啊？怎么没拍到 Where is it? Why didn't you photograph it? (Angry, other) 哈哈，这照片拍的，太像了 Haha, these photos are too similar. (Happy, other)	这张照片 拍的好，拍的好 This photo looks great ! Really great ! (Like, other)

图 5-2 四类模型对比图

从表5-2来看，Seq2seq-emb 的表现最差，这也是意料之中的。因为该模型在生成过程中被不恰当的使用到了词嵌入，导致生成了比传统 Seq2seq 模型更晦涩

表 5-2 人工评估结果

模型类型	$S_{semantics}$	$S_{sentiment}$	$Q_{response}$
ECMP	0.415	0.885	0.390
ECM	0.355	0.870	0.310
Seq2seq-emb	0.280	0.795	0.250
Seq2seq	0.390	0.815	0.360

难懂的句子。

传统 Seq2seq 更多的时候只是对 post 换了一种说法改写后阐述出来，所以人工评判可能会觉得 response 生成的情感和语义都比较符合当前的语境和情感，但是显然这种回复是含金量并不高的。

而 ECM 模型则取得了相对来说不错的成绩，但是因为 ECM 无法自动选择最佳情感，所以在这里只能默认 ECM 的 response 采用和 post 一致的情感，这显然是非常有局限性的，因为没有人希望在愤怒或者伤心的表达时，听到对方同样的回复同样也是愤怒伤感的。而 ECMP 则分别从语义丰富度和情感准确度两个角度分别对模型进行了优化，使得 ECMP 所生成的语句有了较好的效果。

而图5-2则是一种对于现有四种模型分别在同一个 post 下所生成的 response 的示例。

5.4 系统界面

因为用户直接在 IDE 中直接进行交互的体验感并不是很好，而且对于系统的环境配置非常繁琐，所以在完成了原型系统的设计后，希望能有一个更为便捷的交互系统来进行直观的展示，所以本项目采用了 Vue.js 来作为前端，而 Django 作为后端来进行交互系统的设计，其中蚂蚁金服团队提供了一套非常完善的前端套件 Ant Design of Vue 来让开发者快速开发自己的展示平台，所以本项目也是通过这个平台来进行可视化交互界面的设计。虽然 Django 也有其前端界面，但是其开发效率太低，所以不予使用。

ECMP 平台的前端设计模块中包括用户登陆、结果分析和对话互动三个主要模块。具体的设计和实现可以参考项目源码^[22]，在这里不做赘述。

5.4.1 用户登陆页面



图 5-3 交互平台展示图

而点击开始对话按钮之后，会直接进入对话互动界面，并且在输入 post 之后，展示平台会自动给出相应的 response 以及判定需要什么情感进行回复。

5.4.2 数据分析页面

5.4.3 对话互动页面

5.5 本章小结

最终的评估结果证明，ECMP 模型目前优于现有的所有情感对话模型，因为其拥有情感自动选择器，可以生成更为贴近于真实日常对话中的情感表达。而且在之前的情感对话生成中，回复中所嵌入的情感都是单一的情感，但是人类对于情感的感知十分微妙，在言语中所包含的情感也不是只有一个种类，所以 ECMP 中提出了情感向量空间并且假定情感概率的分布在整个向量空间上，从而使得生成的回复不会被单一的情绪所约束。

而为了使得本项目能体现其工程化的能力，所以在最后也在原型系统的基础上基于 Vue.js 和 Django 设计了一整套便捷的交互界面 ECMPPro，用于让用户直观的感受情感对话生成系统的能力。

6 总结与展望

6.1 个人总结

总结来说,本次课题也基本上涵盖了我大学四年的主要技术栈,包括 python、git、TensorFlow、django 以及 Vue.js。因为本人比较偏向于工程化项目,但是在深度学习课题中偏向于科研方向,所以在最后也是做了一些工程化的展示界面,其中使用到了 Vue.js 技术和 Django 框架,这些都是目前比较热门的前后端框架,也是在公司实习过程中所做的技术储备。非常幸运的是能在本次课题中有所用武之地。

从代码管理的角度来看,git 作为版本管理的头号热门工具,理所应当成为了本项目的版本管理工具。而一直以来 GitHub 是首选的代码版本管理平台,所以本次课题的所有 commit 版本都保存在本人的 Github 仓库中。

而因为本次课题为对话生成相关的课题,在代码实现方面也主要使用到 TensorFlow 框架,不过由于原生的 ECM 框架的 TensorFlow 版本过低,导致了許多新版本的功能不兼容的问题,所以在本次课题结束后,将准备使用 TensorFlow2.0 以上版本对项目进行重构,此外整个对话系统的生成和展示都按照预期效果顺利完成。

从工程能力上说,曾经因为没有做过算法类的大型项目,所以本次课题对我也是一个非常大的挑战,而最后的展示系统也是一个纯粹的工程类项目,展示系统的存在让功能更加多样化且交互更加友好。因为不涉及数据库的开发,在开发成本上不会特别难以接收。并且新系统有比较优秀的可维护性所以在不同的系统上的可兼容性会比较好。

6.2 未来展望

对于本课题的未来发展前景,可以非常明显的发现此次课题中不包含知识图谱的构建,所以会导致回复中并没有特别多新颖的信息,在联想方面也有所欠缺,所以在下一个阶段,希望可以构建 ECMP 专属的知识图谱来进行基于主题风格化的情感对话系统的构建。

而 TensorFlow 的兼容性也是一个比较大的挑战，在之前的 ECM 项目中，距离开发者的上一次提交已经是 4 年之前，TensorFlow 的版本也非常老旧所以导致现在的维护和扩展成本非常大，所以下一步的主要工作将会主要围绕在使用 TensorFlow2.x 来改写原版 TensorFlow0.12 的原始系统。

对于目前的交互系统，因为没有上线服务器，所以只能在本地局域网运行。在之后可以将整个交互系统上架为合法备案的网站应用并申请相关的域名，更高阶的目标是将其抽象出对话生成 API 来提供给其他用户更方便地使用和调用。

致谢

感谢父母的生养和陪伴给予我爱与力量，在他们的勤劳与呵护下，给我构筑了一个温馨美好的家庭，愉快的度过 21 年的求学时光。

感谢魏巍导师在整个课题研究过程中的悉心指导，众多颇有深度的理念，让我沉浸于研究性课题的魅力。

感谢爱人张雨佳同学一路以来的支持和信任，每个温柔的拥抱给予了莫大的慰藉与安慰，期待同她的美好未来。

感谢恩师杜晓燕老师的启发和鼓励，让我从一个内向笨拙的学生，逐渐充满自信翻转人生。

感谢发小宋梓贤与我相伴成长嬉笑打闹的十余年时光，激发了我对这个世界最初的好奇和探索。

感谢亲朋好友在每个重要阶段的帮助和勉励，深刻感念于家人的温暖。

感谢三位室友同我分享这大学四年里的诸多美好，教会我上进与成长，同低谷，共奋进。

感谢母校华中科技大学及计算机科学与技术学院，让我从一个计算机小白变成今日模样，从一个初生牛犊到如今的但当涉猎。

参考文献

- [1] ZHOU H, HUANG M, ZHANG T, et al. Emotional Chatting Machine: Emotional Conversation Generation with Internal and External Memory[J/OL]. CoRR, 2017, abs/1704.01074.
<http://arxiv.org/abs/1704.01074>.
- [2] BAHDANAU D, CHO K, BENGIO Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.
- [3] LUONG M-T, PHAM H, MANNING C D. Effective approaches to attention-based neural machine translation[J]. arXiv preprint arXiv:1508.04025, 2015.
- [4] JEAN S, CHO K, MEMISEVIC R, et al. On using very large target vocabulary for neural machine translation[J]. arXiv preprint arXiv:1412.2007, 2014.
- [5] 彭叶红. 基于主题模型与变分自编码的情感对话生成技术研究 [D]. [S.l.]: 华中师范大学, 2019.
- [6] 刘喜凯. 基于对话风格迁移的神经网络对话模型研究 [D]. [S.l.]: 大连理工大学, 2020.
- [7] GHOSH S, CHOLLET M, LAKSANA E, et al. Affect-lm: A neural language model for customizable affective text generation[J]. arXiv preprint arXiv:1704.06851, 2017.
- [8] 刘宁. 人机交互的情感拟人化策略研究 [D]. [S.l.]: 重庆邮电大学, 2019.
- [9] WEI W, LIU J, MAO X, et al. Emotion-aware chat machine: Automatic emotional response generation for human-like emotional interaction[C] // Proceedings of the 28th ACM International Conference on Information and Knowledge Management. 2019: 1401 – 1410.
- [10] BAO F, NEUMANN M, VU N T. CycleGAN-Based Emotion Style Transfer

- as Data Augmentation for Speech Emotion Recognition.[C] // INTERSPEECH. 2019: 2828–2832.
- [11] LI J, GALLEY M, BROCKETT C, et al. A persona-based neural conversation model[J]. arXiv preprint arXiv:1603.06155, 2016.
- [12] GUTHRIE D, ALLISON B, LIU W, et al. A closer look at skip-gram modelling.[C] // LREC: Vol 6. 2006: 1222–1225.
- [13] EMBEDDING. Chinese-Word-Vectors[EB/OL]. .
<https://github.com/Embedding/Chinese-Word-Vectors>.
- [14] MIKOLOV T, KARAFIÁT M, BURGET L, et al. Recurrent neural network based language model[C] // Eleventh annual conference of the international speech communication association. 2010.
- [15] CHO K, VAN MERRIËNBOER B, GULCEHRE C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[J]. arXiv preprint arXiv:1406.1078, 2014.
- [16] MIKOLOV T, CHEN K, CORRADO G, et al. Efficient Estimation of Word Representations in Vector Space[J], 2013.
- [17] GERS F A, SCHMIDHUBER J, CUMMINS F. Learning to forget: Continual prediction with LSTM[J], 1999.
- [18] DEY R, SALEM F M. Gate-variants of gated recurrent unit (GRU) neural networks[C] // 2017 IEEE 60th international midwest symposium on circuits and systems (MWSCAS). 2017: 1597–1600.
- [19] TANG D, WEI F, YANG N, et al. Learning Sentiment-Specific Word Embedding for Twitter Sentiment Classification[C/OL] // Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Baltimore, Maryland: Association for Computational Linguistics, 2014: 1555–1565.
<https://www.aclweb.org/anthology/P14-1146>.

- [20] PLUTCHIK R. A general psychoevolutionary theory of emotion[G] // Theories of emotion. [S.l.] : Elsevier, 1980 : 3–33.
- [21] 王红珍, 李竹林, OTHERS. 软件开发成本估算模型的研究 [J]. 计算机与数字工程, 2012(2012 年 03): 4–6+.
- [22] ALEXFAN. Emotion-Chat-Machine-Pro[EB/OL]. .
<https://github.com/AlexFanw/Emotion-Chat-Machine-Pro>.
- [23] MILLER G. Human memory and the storage of information[J]. IRE Transactions on Information Theory, 1956, 2(3): 129–137.
- [24] LIU C-W, LOWE R, SERBAN I, et al. How NOT To Evaluate Your Dialogue System: An Empirical Study of Unsupervised Evaluation Metrics for Dialogue Response Generation[C/OL] // Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing. Austin, Texas : Association for Computational Linguistics, 2016 : 2122–2132.
<https://www.aclweb.org/anthology/D16-1230>.
- [25] LI J, GALLEY M, BROCKETT C, et al. A diversity-promoting objective function for neural conversation models[J]. arXiv preprint arXiv:1510.03055, 2015.